Guía de Configuración: Sistema RAG de Normas de Tránsito

Esta guía explica los pasos necesarios para configurar el entorno de desarrollo y generar la base de datos local de leyes y normativas.

1. Requisitos del Sistema (Dependencias de OS)

Para procesar documentos escaneados (OCR) y PDFs, es necesario instalar herramientas del sistema:

En Fedora (tu sistema actual):

```
sudo dnf install tesseract tesseract-langpack-spa poppler-utils
```

En Ubuntu/Debian:

```
sudo apt update
sudo apt install tesseract-ocr tesseract-ocr-spa poppler-utils
```

2. Entorno de Python

Se recomienda usar un entorno virtual para mantener las dependencias aisladas.

1. **Crear y activar el entorno:**

   ```
   python -m venv venv
   source venv/bin/activate  # En Linux/Mac
   # venv\Scripts\activate   # En Windows
   ```

2. **Instalar dependencias de Python:**

   ```
   pip install pypdf python-docx beautifulsoup4 pdf2image pytesseract Pillow
   ```

3. Generación de la Base de Datos Local

El archivo de la base de datos (`data/normas.db`) **no se sube al repositorio** para evitar conflictos. Cada desarrollador debe generarla siguiendo estos pasos:

1. Asegúrate de tener los documentos base en la carpeta `data/raw/` .
2. Ejecuta el script de recolección:

   ```
   python collect.py
   ```

¿Qué hace este script?

- Crea la base de datos SQLite localmente.
- Procesa PDFs (normales y escaneados), DOCX y archivos HTML.
- **Evita duplicados:** Utiliza un hash MD5 del contenido, por lo que si renombras un archivo pero el contenido es igual, no se duplicará.
- Genera un reporte en `data/reporte_validacion.csv` para la revisión manual del equipo de datos.

4. Estructura de Datos y Verificación

Una vez ejecutado, encontrarás dos archivos nuevos en tu carpeta `data/` :

- `normas.db` : Contiene todo el texto extraído listo para ser procesado por el sistema RAG.
- `reporte_validacion.csv` : Debe ser utilizado por el equipo de datos para validar la integridad de las fuentes y la calidad de la extracción.

> **Nota:** Nunca hagas commit del archivo `.db` . El archivo `.gitignore` ya debería estar configurado para ignorar `data/*.db` .